Progetto Nonparametric Statistics

Metodi del corso e dataset candidati · ottobre 2026

> Un riassunto dei metodi del corso e sei dataset candidati, per scegliere insieme su cosa lavorare.
>
> Il progetto chiede un **dataset reale**, una **research question** posta da uno stakeholder realistico, risultati sia **statistici** sia tradotti in **conclusioni per lo stakeholder**, e di usare più metodi possibile, ma **ognuno con un motivo**.

I metodi del corso, in parole semplici

L'idea comune a tutto il corso: non assumere che i dati seguano una distribuzione nota (normale e simili) e lasciare che siano i dati a parlare. Per ogni metodo: cosa fa e cosa serve nei dati per usarlo.

PARTE I – ESPLORAZIONE

Depth measures. Per un solo numero sappiamo cos'è la mediana e cosa sta agli estremi. Per vettori (prezzo, voto, posizione) o per intere curve non è ovvio. La *depth* misura quanto un'osservazione è "centrale" rispetto alle altre. Da qui si ottengono una mediana, una classifica dal più tipico al più strano, e un boxplot anche per le curve (*functional boxplot*, *outliergram*) per trovare gli outlier.
Serve: osservazioni con più variabili, o meglio ancora curve.

Dati funzionali. Ogni unità statistica è una curva, non un numero: il consumo elettrico di una casa nelle 24 ore, il prezzo di un appartamento nei 365 giorni dell'anno. Quasi tutti i metodi del corso hanno una versione per le curve, ed è un tema su cui i docenti puntano molto (versione da 8 CFU).
Serve: misure ripetute nel tempo, sulla stessa griglia per ogni unità.

PARTE II – INFERENZA

Test sui ranghi (sign test, Wilcoxon, Mann-Whitney). Si sostituiscono i valori con la loro posizione in classifica e si confrontano le classifiche. Funzionano senza normalità e non si fanno trascinare dagli outlier.
Serve: due gruppi da confrontare, oppure dati appaiati (la stessa unità prima e dopo).

Permutation test. È il cuore del corso. Se l'ipotesi nulla è vera ("il gruppo non conta"), le etichette dei gruppi sono intercambiabili. Le si rimescola migliaia di volte, si ricalcola la statistica ogni volta e si guarda quanto è estremo il valore osservato rispetto a quelli rimescolati. Con dati appaiati, invece di rimescolare si cambia a caso il segno delle differenze. Funziona con qualunque statistica: medie, mediane, ANOVA, regressione, curve. Per le curve esiste l'*Interval-Wise Testing* (IWT), che dice anche *dove* le curve differiscono ("solo tra le 17 e le 20").
Serve: un confronto (gruppi, trattamento, prima/dopo) e unità indipendenti tra loro.

Bootstrap. Si ricampionano i dati con reinserimento per vedere quanto varierebbe una stima se si ripetesse lo studio. Dà intervalli di confidenza e test per quantità di cui non si conosce la distribuzione: mediane, differenze, coefficienti di regressione.
Serve: unità indipendenti e un n non minuscolo.

PARTE III – REGRESSIONE NONPARAMETRICA

Kernel, spline, GAM. Invece di imporre y = a + bx, si lascia che la forma della curva f(x) emerga dai dati. Il *kernel* fa medie locali pesate; le *spline* sono pezzi di polinomio raccordati in modo liscio; i *GAM* sommano funzioni lisce di più variabili. La parte semiparametrica mescola effetti lineari e lisci.
Serve: variabili continue con effetti non lineari e abbastanza dati.

Spline con penalizzazione differenziale. È la parte della prof. Sangalli (pacchetto fdaPDE): smoothing su un dominio spaziale, per esempio una mappa di Milano, che rispetta la forma e i confini del territorio.
Serve: dati con coordinate geografiche, idealmente molti punti sparsi su un territorio.

Regressione quantile. Non si modella la media ma un quantile, per esempio il 90° percentile. Risponde a domande come "cosa fa salire i picchi?" o "i più cari reagiscono come gli economici?".
Serve: una risposta in cui le code contano.

Survival analysis. Si modella il tempo fino a un evento (guasto, abbandono, morte, chiusura), con *censura*: per alcune unità l'evento non è ancora stato osservato quando lo studio finisce. Kaplan-Meier e Nelson-Aalen stimano la curva di sopravvivenza; il modello di Cox misura l'effetto delle covariate.
Serve: una variabile "tempo fino a" con censura. È il requisito più difficile da trovare.

PARTE IV – PREVISIONE

Conformal prediction. Si prende un modello qualsiasi e ci si costruiscono attorno intervalli di previsione con copertura garantita (per esempio 90%), senza ipotesi distributive. Esiste anche per le curve: bande di previsione per un'intera curva futura.
Serve: qualcosa di sensato da prevedere, e abbastanza dati da tenerne una parte per la calibrazione.

Cosa rende un dataset adatto al corso

Ogni caratteristica del dataset "sblocca" uno o più metodi.

Caratteristica del dataset	Metodi che sblocca
Confronto naturale (gruppi, prima/dopo, trattamento)	Ranghi, permutation test, bootstrap
Curve (misure ripetute su una griglia)	Depth e test funzionali, IWT
Covariate continue con effetti non lineari	Kernel, spline, GAM
Coordinate geografiche	Spline con penalizzazione differenziale
Code o picchi che contano	Regressione quantile
Tempo fino a un evento, con censura	Kaplan-Meier, Cox
Qualcosa da prevedere	Conformal prediction

In più servono dati chiaramente non gaussiani (giustificano l'approccio) e unità indipendenti: permutazioni e bootstrap non funzionano su una serie temporale rimescolata senza accorgimenti.

I sei dataset candidati

Per ognuno: da dove viene, cosa contiene, la domanda di uno stakeholder, come entrerebbero i metodi del corso e pro e contro.

1 Airbnb a Milano e le Olimpiadi Milano-Cortina 2026

FONTE

Inside Airbnb – Get the data (sezione Milan, Lombardia, Italy). Licenza CC BY 4.0. Gli snapshot trimestrali degli ultimi 12 mesi sono scaricabili gratis; quelli più vecchi vanno richiesti.

COSA CONTIENE

`listings.csv` (un annuncio per riga: prezzo, coordinate, quartiere, tipo di alloggio, host, recensioni), `calendar.csv` (disponibilità giorno per giorno per l'anno successivo), `reviews.csv` (data di ogni recensione, utile come indicatore delle prenotazioni), confini dei quartieri in GeoJSON.

STAKEHOLDER E DOMANDA

L'Assessorato al Turismo del Comune di Milano. *"Le Olimpiadi (6–22 febbraio 2026) hanno fatto salire i prezzi degli affitti brevi? Dove, per quali alloggi, e quanti host sono entrati sul mercato solo per l'evento?"*

COME ENTRANO I METODI

- *Ranghi e permutazioni:* lo stesso annuncio prima e durante i Giochi forma una coppia, quindi Wilcoxon signed-rank e permutazioni con cambio di segno.
- *Bootstrap:* intervallo di confidenza sull'aumento mediano di prezzo.
- *Spaziale (fdaPDE):* mappa liscia del rincaro su Milano, per vedere se si concentra vicino alle sedi (San Siro, Santa Giulia, Rho Fiera, Assago).
- *Regressione quantile:* gli annunci di lusso e quelli economici hanno reagito allo stesso modo?
- *Survival:* durata di vita degli annunci comparsi a fine 2025 (Kaplan-Meier, Cox), censurati all'ultimo snapshot.
- *Funzionale:* curve mensili di recensioni o di disponibilità per annuncio; depth per gli annunci anomali.
- *Conformal:* forbice di prezzo "giusta" per un nuovo host.

PRO

- Attuale, locale, originale.
- Copre quasi tutto il corso, inclusa la parte spaziale.
- Prezzi molto asimmetrici con outlier: il nonparametrico è giustificato.

CONTRO

- Fotografie trimestrali, non serie continue. Da verificare se `calendar.csv` contiene ancora i prezzi giornalieri.
- Confondente forte: febbraio è già alta stagione (la Fashion Week segue di poco i Giochi). Serve un confronto: febbraio 2025 (su richiesta) o città di controllo come Bergamo o Bologna.
- Pulizia dei dati non banale (prezzi come testo, annunci duplicati o inattivi).

2 Smart meter di Londra e la tariffa dinamica (2013)

FONTE

London Datastore – SmartMeter Energy Consumption Data in London Households, UK Power Networks, licenza CC BY 4.0. Versione più comoda su Kaggle: Smart meters in London, con meteo giornaliero e classe socioeconomica (ACORN) per famiglia.

COSA CONTIENE

Consumi ogni mezz'ora di 5.567 famiglie londinesi, da novembre 2011 a febbraio 2014. Nel 2013 circa 1.100 famiglie avevano una tariffa dinamica (prezzo alto 67,20 p/kWh, normale 11,76, basso 3,99, comunicato il giorno prima); le altre circa 4.500 pagavano una tariffa fissa di 14,23 p/kWh.

STAKEHOLDER E DOMANDA

Il distributore di energia o l'autorità di regolazione. *"Le tariffe dinamiche spostano davvero i consumi fuori dalle ore di punta? Per quali famiglie funzionano meglio?"*

COME ENTRANO I METODI

- *Funzionale:* ogni famiglia ha una curva di consumo giornaliera (48 punti). Depth, functional boxplot e outliergram per i profili anomali.
- *Permutation test funzionale e IWT:* confronto tariffa dinamica vs fissa, con l'indicazione delle ore in cui la differenza è significativa.
- *Prima/dopo:* il 2012 (tutti a tariffa fissa) contro il 2013 permette un confronto "differenza nelle differenze" via permutazione.
- *Bootstrap:* intervallo di confidenza sulla riduzione del consumo nelle ore di punta.
- *GAM:* consumo in funzione della temperatura, relazione tipicamente non lineare.
- *Regressione quantile:* i picchi di consumo, che sono ciò che interessa alla rete.
- *Conformal funzionale:* banda di previsione per la curva di consumo del giorno dopo.

PRO

- Quasi-esperimento vero: il disegno più pulito dei sei.
- Dati funzionali perfetti.
- Le famiglie sono unità indipendenti.

CONTRO

- Niente survival e niente spazio vero (solo la classe ACORN).
- Dati del 2013, anche se il tema delle tariffe dinamiche è attualissimo.
- File completo di circa 10 GB, ma basta un sottocampione o la versione Kaggle aggregata.

3 Qualità dell'aria a Milano (ARPA Lombardia)

FONTE

Pacchetto R ARPALData, che scarica dati di qualità dell'aria e meteo di ARPA Lombardia con una funzione. Gli stessi dati sono sul portale open data della Regione.

COSA CONTIENE

Misure orarie o giornaliere di inquinanti (NO_2, PM10, PM2.5, ozono...) per stazione, più le stazioni meteo (temperatura, vento, pioggia), per molti anni.

STAKEHOLDER E DOMANDA

Il Comune di Milano. *"Area B (attiva da febbraio 2019) ha ridotto l'NO_2 in città, al netto del meteo?"*

COME ENTRANO I METODI

- *Funzionale:* curve orarie giornaliere di NO_2; depth per i giorni anomali (Capodanno, sabbia sahariana); IWT per capire in quali ore cambia qualcosa.
- *GAM:* il meteo è il confondente principale e ha effetti non lineari.
- *Regressione quantile:* i superamenti delle soglie di legge.
- *Conformal:* previsione dei giorni di allerta.

PRO

- Dati scaricabili in una riga, ben documentati.
- Molto in linea con il corso (le lezioni usano già dati milanesi).

CONTRO

- I giorni sono una serie temporale autocorrelata: permutazioni e bootstrap vanno adattati.
- L'effetto di Area B è difficile da isolare dal meteo e dal trend.
- La survival sarebbe forzata; probabilmente lo sceglieranno in molti.

4 Mortalità giornaliera per comune e ondate di calore (ISTAT)

FONTE

ISTAT – Dati di mortalità, file "decessi giornalieri" in CSV. Dati provvisori, aggiornati ogni trimestre.

COSA CONTIENE

Decessi giornalieri per comune di residenza, per sesso e classi di età di 5 anni, dal 2011 a giugno 2026, per tutti i comuni italiani. La temperatura va aggiunta da un'altra fonte (per esempio il meteo di ARPALData per la Lombardia).

STAKEHOLDER E DOMANDA

La Regione Lombardia (Direzione Welfare). *"Quanto eccesso di mortalità causano le ondate di calore estive, in quali zone e per quali fasce d'età? Dove servono più interventi per gli anziani?"*

COME ENTRANO I METODI

- *Funzionale:* per ogni area e anno, la curva dei decessi lungo l'anno. Depth per gli anni anomali (2020, estati 2022–2023); IWT per individuare le settimane con eccesso significativo.
- *GAM:* la relazione temperatura–mortalità è un classico esempio non lineare (a forma di U o di J).
- *Spaziale (fdaPDE):* mappa liscia dell'eccesso di mortalità sulla Lombardia.
- *Regressione quantile e permutazioni:* differenze tra fasce d'età e tra zone urbane e rurali.
- *Conformal:* banda dei decessi "attesi"; i giorni fuori banda segnalano un eccesso.

PRO

- Italiano e rilevante per la sanità pubblica; stakeholder molto credibile.
- Ha spazio, curve e una relazione non lineare da manuale.

CONTRO

- A livello di singolo comune i numeri sono piccoli: conviene aggregare (province o distretti).
- Serve unire una fonte di temperatura.
- Niente survival (sono conteggi, non persone seguite nel tempo). Il COVID è abusato: meglio puntare sul caldo.

5 Pazienti con scompenso cardiaco (UCI)

FONTE

UCI – Heart failure clinical records, licenza CC BY 4.0.

COSA CONTIENE

299 pazienti con 13 variabili cliniche (età, frazione di eiezione, creatinina, sodio, pressione alta, diabete, fumo...), il tempo di follow-up in giorni e l'indicatore di morte durante il follow-up.

STAKEHOLDER E DOMANDA

Il reparto di cardiologia di un ospedale. *"Quali pazienti sono ad alto rischio e vanno seguiti più da vicino dopo la dimissione?"*

COME ENTRANO I METODI

- *Survival:* Kaplan-Meier per gruppi (per esempio frazione di eiezione bassa vs normale), log-rank test (è un test sui ranghi), modello di Cox.
- *Spline:* effetti non lineari di creatinina ed età sul rischio.
- *Permutazioni e bootstrap:* confronti tra gruppi di pazienti e intervalli di confidenza sugli hazard ratio.
- *Depth multivariata:* profili clinici anomali.
- *Conformal:* classificazione del rischio con garanzia di copertura.

PRO

- L'unico in cui la survival è il cuore della domanda.
- Piccolo e pulito: si lavora subito sui metodi, non sulla pulizia.

CONTRO

- Niente curve e niente spazio: metà del corso resta fuori.
- Con 299 pazienti GAM e conformal hanno poco margine.
- Molto usato su Kaggle, quindi poco originale.

6 Formula 1 e degrado delle gomme

FONTE

Pacchetto R f1dataR, che si appoggia alla libreria Python FastF1 e al database storico della F1.

COSA CONTIENE

Tempi sul giro, mescola e numero di giri delle gomme, pit stop, meteo e telemetria per ogni gara delle ultime stagioni.

STAKEHOLDER E DOMANDA

Lo stratega di un team. *"Quale mescola conviene, su quale pista, e quando fermarsi ai box?"*

COME ENTRANO I METODI

- *Funzionale:* ogni stint è una curva di tempi sul giro; depth per gli stint anomali.
- *Permutazioni:* ANOVA tra mescole e piste.
- *GAM:* degrado in funzione dei giri percorsi e della temperatura della pista.
- *Survival:* durata dello stint fino al pit stop, censurata da safety car o fine gara.
- *Conformal:* intervallo di previsione del giro successivo.

PRO

- L'unico con survival, curve e confronti tutti naturali insieme.
- Dati ricchi e divertenti.

CONTRO

- Stakeholder di nicchia.
- Tempi sul giro "sporchi" (carburante che cala, traffico, bandiere).
- Stint dello stesso pilota e della stessa gara non indipendenti.

Confronto e proposta

Le opzioni più forti sono **Airbnb Milano** (più originale e completa, ma più lavoro sui dati) e **smart meter di Londra** (il disegno più pulito, centrato sui dati funzionali). La **mortalità ISTAT** è l'alternativa italiana con spazio e curve.

Dataset	Confronto	Curve	Non lineare	Spazio	Code	Survival	Previsione	Unità indip.	Originalità	Pulizia dati
1. Airbnb Milano	✓	~	✓	✓	✓	✓	✓	✓	Alta	Tanta
2. Smart meter Londra	✓	✓	✓	×	✓	×	✓	✓	Media	Media
3. Aria Milano	~	✓	✓	~	✓	×	✓	×	Bassa	Poca
4. Mortalità ISTAT	~	✓	✓	✓	✓	×	✓	~	Media	Media
5. Scompenso cardiaco	✓	×	✓	×	~	✓	~	✓	Bassa	Minima
6. Formula 1	✓	✓	✓	×	~	✓	✓	~	Media	Media

✓ presente in modo naturale · ~ presente ma con limiti · × assente o forzato

Nessun dataset copre tutto, e non serve: è meglio spiegare perché un metodo non si applica che forzarlo.

Fonti

- Syllabus 2026–2027, Nonparametric Statistics, Politecnico di Milano (nella cartella del corso)
- Inside Airbnb – Get the data
- London Datastore – SmartMeter Energy Consumption Data in London Households
- Kaggle – Smart meters in London
- ARPALData su CRAN
- ISTAT – Dati di mortalità
- UCI – Heart failure clinical records
- f1dataR su CRAN