Smart meters in London – scheda del dataset

Progetto Nonparametric Statistics · dataset Kaggle di jeanmidev, basato sul trial Low Carbon London

UNITÀ	PERIODO	RISOLUZIONE
~5.566 famiglie londinesi	**Nov 2011 – Feb 2014**	**Ogni 30 minuti** (48 misure/giorno, kWh)

GRUPPI TARIFFARI	FONTE ORIGINALE	EXTRA SU KAGGLE
~1.100 ToU · ~4.450 Std	**UK Power Networks** (London Datastore)	**Meteo, classe ACORN, festività**

Da dove vengono i dati

I dati vengono da **Low Carbon London** (2011–2014), un progetto di UK Power Networks finanziato da Ofgem e analizzato da Imperial College. Durante **tutto il 2013** circa 1.100 famiglie (1.122 secondo la documentazione ufficiale) hanno avuto una **tariffa dinamica (dToU)**, gestita da EDF Energy. Le altre famiglie sono rimaste a tariffa fissa (**Std**, 14,23 p/kWh) e fanno da gruppo di riferimento.

- **Tre livelli di prezzo:** alto 67,20 p/kWh, normale 11,76, basso 3,99. Il "giorno tariffario" va dalle 5:00 alle 5:00.
- **Preavviso:** SMS e display in casa alle 8:00 del giorno prima.
- **Due tipi di eventi.** *Constraint Management:* 13 eventi (21 giorni) con un picco di prezzo alto tra due fasce a prezzo basso, per alleggerire la rete. *Supply Following:* blocchi di 3, 6, 12 o 24 ore a prezzo alto o basso, per seguire la produzione.
- **Reclutamento su base volontaria** tra i clienti EDF, con quote per classe socioeconomica (ACORN) simili a quelle di Londra in entrambi i gruppi. L'assegnazione **non risulta randomizzata**.
- **Risultato ufficiale:** negli eventi a prezzo alto la riduzione media di domanda è stata del **7–8% circa** (IC 95%: 7,1–8,4%), cioè 26–72 W per famiglia.

I file del dataset Kaggle

File	Contenuto	Colonne principali
`informations_households.csv`	Una riga per famiglia: gruppo tariffario, classe socioeconomica e blocco in cui stanno i suoi dati	`LCLid`, `stdorToU` (Std/ToU), `Acorn`, `Acorn_grouped`, `file`
`halfhourly_dataset/`	Formato lungo: una riga per famiglia e mezz'ora. 112 file (`block_0` … `block_111`), oltre 160 milioni di righe	`LCLid`, `tstp`, `energy(kWh/hh)`
`hhblock_dataset/`	**Formato largo:** una riga per famiglia e giorno, con le 48 mezz'ore in colonna. È già una curva per riga (~3,5 milioni di righe)	`LCLid`, `day`, `hh_0` … `hh_47`
`daily_dataset/`	Statistiche giornaliere per famiglia	`energy_sum`, `_mean`, `_median`, `_max`, `_min`, `_std`, `_count`
`acorn_details.csv`	Profilo socio-demografico di ogni gruppo ACORN (indici rispetto alla media UK)	categoria, variabile, indici per `ACORN-A` … `Q`
`weather_*_darksky.csv`	Meteo di Londra, orario (~21.000 righe) e giornaliero (~880 righe), da Dark Sky	temperatura, temperatura percepita, umidità, vento, nuvolosità
`uk_bank_holidays.csv`	Festività nazionali	data, nome

ACORN divide le famiglie in 6 categorie e 17 gruppi (da A a Q); `Acorn_grouped` le riassume in *Affluent*, *Comfortable* e *Adversity*. Le famiglie con classe `ACORN-U` o mancante non hanno informazione utile.

La nostra domanda

> **Stakeholder:** il distributore di energia (UK Power Networks) o il regolatore (Ofgem).
> **Domanda:** la tariffa dinamica cambia davvero il profilo di consumo delle famiglie rispetto alla tariffa fissa? In quali ore del giorno, di quanto, e per quali famiglie funziona meglio?

Perché il dataset si presta

- **Unità indipendenti:** la famiglia, non il singolo giorno.
- **Curve pronte:** `hhblock` dà già una curva giornaliera da 48 punti per famiglia, ideale per depth e test funzionali.
- **Tre confronti possibili:** ToU vs Std nel 2013; per le famiglie ToU, giorni con evento vs giorni normali; 2012 (tutti a tariffa normale) vs 2013, cioè una "differenza nelle differenze".
- **Covariate:** temperatura (effetto non lineare) e classe ACORN.
- **Dati non gaussiani:** consumi asimmetrici, molti valori vicini a zero e famiglie con picchi estremi.

Metodi del corso coinvolti

- **Depth, functional boxplot, outliergram:** profili tipici e anomali.
- **Permutation test funzionale e IWT:** ToU vs Std, e in quali mezz'ore la differenza è significativa.
- **Ranghi e bootstrap:** confronti su sintesi come consumo di picco, con intervalli di confidenza.
- **GAM:** consumo in funzione di temperatura e ora.
- **Regressione quantile:** la tariffa abbassa soprattutto i picchi?
- **Conformal funzionale:** banda per la curva del giorno dopo.

Cose a cui fare attenzione

- **Il calendario degli eventi non è nel dataset Kaggle.** Per sapere quando il prezzo era alto o basso serve il file *Tariffs (XLSX)* sul London Datastore. Senza, confrontiamo solo medie annuali e diluiamo l'effetto.
- **Gruppi non randomizzati:** chi ha scelto la tariffa dinamica può essere diverso di partenza. Il confronto con il 2012 e il controllo per ACORN servono proprio a questo, e va detto nel report.
- **Copertura variabile:** i contatori sono entrati e usciti in momenti diversi. Va controllato quanti giorni ha ogni famiglia nel 2012 e nel 2013.
- **Qualità dei dati:** ci sono valori mancanti, giorni con meno di 48 misure e alcuni orari "irregolari" (es. 15:13:37 invece di 15:30). L'ultimo giorno (28/02/2014) è incompleto.
- **Dimensioni:** il formato mezz'orario pesa circa 10 GB. Conviene lavorare su `hhblock` e su un sottocampione bilanciato di famiglie.
- **Meteo:** un solo punto per tutta Londra, che va bene come covariata comune a tutte le famiglie.

Fonti: Kaggle – Smart meters in London · London Datastore – SmartMeter Energy Consumption Data (tariffe e file Tariffs XLSX) · Imperial College, LCL Report D4 (2014) (disegno del trial, eventi, risultati) · LCL dToU trial data record (1.122 famiglie dToU) · analisi esplorativa del dataset Kaggle (numeri di righe e qualità dei dati).